



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS RUSSAS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

PEDRO HENRIQUE RESENDE MARQUES

**DAS REGRAS AO RACIOCÍNIO: EVOLUÇÃO DA EXTRAÇÃO DE ENTIDADES
PARA ASSISTENTES DE INTELIGÊNCIA ARTIFICIAL**

RUSSAS

2026

PEDRO HENRIQUE RESENDE MARQUES

DAS REGRAS AO RACIOCÍNIO: EVOLUÇÃO DA EXTRAÇÃO DE ENTIDADES PARA
ASSISTENTES DE INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado
ao curso de graduação em Ciência da
Computação da Universidade Federal do
Ceará, como requisito parcial para obtenção
do título de Bacharel em Ciência da
Computação.

Orientador: Prof. Dr. Alexandre Matos Arruda

RUSSAS

2026

PEDRO HENRIQUE RESENDE MARQUES

DAS REGRAS AO RACIOCÍNIO: EVOLUÇÃO DA EXTRAÇÃO DE ENTIDADES PARA
ASSISTENTES DE INTELIGÊNCIA ARTIFICIAL

Trabalho de Conclusão de Curso apresentado
ao curso de graduação em Ciência da
Computação do Campus de Russas da
Universidade Federal do Ceará, como requisito
parcial à obtenção do grau de Bacharel em
Ciência da Computação.

Aprovado em: __/__/____.

BANCA EXAMINADORA

Prof. Dr. Alexandre Matos Arruda (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Tiago Martins da Cunha
Universidade da Integração Internacional da Lusofonia Afro-Brasileira (UNILAB)

Prof. Dr. José Wellington Franco da Silva
Universidade Federal do Ceará (UFC)

RESUMO

A extração de entidades é uma tarefa fundamental na compreensão de linguagem natural por assistentes de inteligência artificial (IA). Sistemas tradicionais baseados em regras exigem esforço manual intenso e conhecimento especializado para criação de regras detalhadas e mapeamento preciso de sentenças. Com o surgimento de modelos de linguagem de grande porte (Large Language Models – LLMs), como a família GPT, o processo de extração tornou-se mais flexível e adaptável, ainda que com novas limitações e desafios. Este trabalho apresenta uma solução em Python que utiliza a API GPT-4.1 Nano para extrair entidades a partir de comandos de usuários, bem como compreender e classificar sentenças. São discutidas a evolução das técnicas de extração de entidades, desde abordagens manuais e baseadas em regras, passando por modelos estatísticos, até métodos apoiados em LLMs. O estudo compara o desempenho da GPT-4.1 Nano com um modelo estatístico de Conditional Random Fields (CRF) e com uma anotação de referência baseada em regras estruturada a partir do corpus BOSQUE. Os resultados mostram que, nas condições avaliadas, os métodos tradicionais apresentam desempenho superior em métricas agregadas de precisão e cobertura, enquanto o LLM se destaca pela flexibilidade, pela capacidade de sugerir rótulos adicionais e pela redução potencial de esforço de desenvolvimento. São também discutidas limitações importantes, como erros de classificação, alucinações e questões de reprodutibilidade.

Palavras-chave: extração de entidades; reconhecimento de entidades nomeadas; modelos de linguagem de grande porte; LLM; assistentes de IA.

ABSTRACT

Entity extraction is a fundamental task in natural language understanding for AI assistants. Traditional rule-based systems required extensive manual effort and specialized knowledge to create detailed rules and accurately map sentences. With the emergence of large language models (LLMs), such as the GPT-4.1 family, extraction has become more flexible and adaptable, although new limitations and challenges arise. This work presents a Python-based solution that leverages the GPT-4.1 Nano API to extract entities from user commands, as well as to understand and classify sentences. We discuss the evolution of entity extraction techniques from manual and rule-based approaches, through statistical models, to LLM-based methods. The study compares the performance of GPT-4.1 Nano with a statistical Conditional Random Fields (CRF) model and with a rule-based reference annotation derived from the BOSQUE corpus. The results show that, under the evaluated conditions, traditional methods outperform the LLM in aggregate precision and recall metrics, while the LLM stands out for its flexibility, ability to suggest additional labels, and potential to reduce development effort. Important limitations such as misclassifications, hallucinations, and reproducibility issues are also discussed.

Keywords: entity extraction; named entity recognition; large language models; LLM. AI assistants.

LISTA DE FIGURAS

Figura 1 – Prompt para a LLM comparar com o modelo estatístico CRF.....	12
Figura 2 – Prompt para a LLM comparar com o modelo baseado em regras.....	13

LISTA DE QUADROS

Quadro 1 – Relatório de métricas de NER: CRF x GPT-4.1 Nano.....	15
Quadro 2 – Relatório de métricas de POS tagging: anotação BOSQUE x GPT-4.1 Nano.....	16

LISTA DE ABREVIATURAS E SIGLAS

IA	Inteligência Artificial
LLM	Large Language Models
API	Application Programmer Interface
CRF	Conditional Random Fields
NER	Named Entity Recognition

SUMÁRIO

1 INTRODUÇÃO.....	1
2 OBJETIVOS.....	4
2.1 Objetivo Geral.....	4
2.2 Objetivos Específicos.....	4
3 FUNDAMENTAÇÃO TEÓRICA.....	5
3.1 Reconhecimento de Entidades Nomeadas.....	5
3.2 Modelos Estatísticos de Sequência.....	5
3.3 Modelos de Linguagem de Grande Porte.....	6
3.4 Engenharia de Prompt.....	6
4 REVISÃO BIBLIOGRÁFICA.....	7
4.1 Modelos Baseados em Regras para Extração de Entidades.....	7
4.2 Modelos Estatísticos para NER.....	7
4.3 Abordagens com LLMs para Extração de Entidades.....	8
5 DESCRIÇÃO DO PROBLEMA EM ESTUDO.....	9
6 METODOLOGIA.....	10
6.1 Dataset e Pré-Processamento.....	10
6.2 Modelos de Referência.....	11
6.3 Modelo de Linguagem GPT-4.1 Nano.....	11
6.4 Engenharia de Prompts.....	12
6.4.1 Primeiro Prompt: Extração em Formato IOB (comparação com CRF).....	12
6.4.2 Segundo Prompt: Rotulagem UPOS e Intenção (comparação com BOSQUE).....	13
6.5 Mapeamento de Entidades, Métricas e Procedimentos de Avaliação.....	13
6.6 Natureza Exploratória do Estudo.....	14
7 RESULTADOS.....	15
7.1 Resultados para NER: CRF x GPT-4.1 Nano.....	15
7.2 Resultados para POS Tagging: BOSQUE x GPT-4.1 Nano.....	15
7.3 Entidades e Rótulos Identificados Apenas pelo LLM.....	16
7.4 Análise de Erros da GPT-4.1 Nano.....	17
7.4.1 Erros de Tipo de Entidade.....	17
7.4.2 Erros de Fronteira de Entidade.....	17
7.4.3 Alucinações e Marcação Excessiva.....	17
7.4.4 Inconsistências de Formato.....	18
8 CONCLUSÕES.....	19
8.1 Considerações Finais.....	19
8.2 Verificação dos Objetivos Atingidos.....	19
8.3 Limitações do Estudo.....	20
8.4 Sugestões para Trabalhos Futuros.....	20
REFERÊNCIAS.....	22

1 INTRODUÇÃO

Assistentes de inteligência artificial têm se consolidado como ferramentas essenciais para automatizar tarefas cotidianas, como agendamento de compromissos, obtenção de informações e apoio à tomada de decisão (IOKU; SONG; WATAMURA, 2024). Ao integrar diferentes tecnologias de **processamento de linguagem natural (PLN)**, esses sistemas buscam ampliar sua usabilidade, qualidade e acurácia na interação com usuários. Historicamente, assistentes baseados em **IA** foram construídos sobre sistemas baseados em regras, nos quais respostas e ações eram previamente definidas e recuperadas a partir de bases de dados, de acordo com entidades identificadas na consulta do usuário (JIVANI; MALVANKAR; SHANKARMANI, 2018). Embora funcionais, tais abordagens apresentavam baixa flexibilidade e demandavam elevado esforço manual para definição de regras, intenções e padrões linguísticos, frequentemente exigindo a atuação conjunta de linguistas e especialistas de domínio. Com o avanço do PLN, modelos estatísticos passaram a ser empregados na rotulagem de sequências e no reconhecimento de entidades nomeadas, reduzindo parte da dependência de regras rígidas (FLORIAN et al., 2004). Mais recentemente, o desenvolvimento acelerado de Modelos de Linguagem de Grande Porte (LLMs – Large Language Models) provocou uma mudança significativa no campo, ao permitir generalização mais robusta, melhor compreensão semântica e maior capacidade de lidar com contextos complexos (YANG et al., 2024), (YAO et al., 2024). Nesse cenário, a extração de entidades tornou-se um caso de uso emblemático, ao migrar de um processo intensamente manual para métodos mais automáticos e adaptativos.

A extração de entidades nomeadas é etapa central em diversos sistemas de assistentes virtuais, chatbots e aplicações de diálogo: a partir dela é possível interpretar corretamente intenções, parâmetros e restrições presentes nos enunciados dos usuários (MOHIT, 2014). Em arquiteturas tradicionais, essa etapa depende de dicionários e ontologias cuidadosamente elaboradas, regras linguísticas específicas para cada domínio e modelos estatísticos treinados em corpora anotados manualmente.

Em muitos cenários, essas soluções clássicas permanecem como padrão, principalmente por apresentarem desempenho estável em tarefas bem definidas. Entretanto, a evolução recente de LLMs levanta uma questão prática relevante: até que ponto esses modelos podem, na prática, complementar ou substituir técnicas estabelecidas em tarefas de anotação linguística, como NER e etiquetagem morfossintática?

A importância do tema decorre de dois fatores principais:

(i) Do ponto de vista tecnológico, LLMs prometem reduzir o esforço manual de desenvolvimento de regras e modelos específicos, especialmente pela possibilidade de adaptação via prompts; e

(ii) Do ponto de vista científico, ainda é necessário caracterizar, com dados empíricos, em que condições e com quais limitações LLMs se comparam a abordagens tradicionais em tarefas de anotação linguística.

Em vez de assumir que LLMs substituem automaticamente modelos existentes, este trabalho parte de uma perspectiva mais cautelosa: realizar uma avaliação exploratória, em escala controlada, para verificar se um LLM compacto, acessível via API, é capaz de se aproximar do desempenho de um modelo estatístico baseado em CRF e de uma anotação de referência baseada em regras, bem como identificar tipos de erro e pontos de atenção na sua utilização prática.

Diante desse contexto, o problema de pesquisa deste trabalho pode ser enunciado da seguinte forma: Como um modelo de linguagem de grande porte, especificamente a variante GPT-4.1 Nano acessível via API no período do estudo, se compara a abordagens tradicionais (modelo estatístico de CRF e anotação de referência baseada em regras) em tarefas de extração de entidades e etiquetagem morfosintática em português, considerando as limitações de reprodutibilidade e de tamanho de conjunto de dados?

Em termos metodológicos, a pesquisa foi conduzida em etapas:

(i) Levantamento bibliográfico sobre extração de entidades, modelos estatísticos, sistemas baseados em regras e LLMs.

(ii) Seleção e preparação de corpos anotados por linguistas (CRF e BOSQUE).

(iii) Desenvolvimento de uma API em Django para comunicação com a GPT-4.1 Nano.

(iv) Definição e refinamento de prompts para extração de entidades (IOB) e rotulagem POS (UPOS) com identificação de intenção.

(v) Execução de experimentos com conjuntos de sentenças específicas (150 sentenças para comparação com o CRF e 1167 sentenças para comparação com o modelo baseado em regras).

(vi) Cálculo de métricas de desempenho (precisão e cobertura), bem como análise de casos discrepantes.

(vii) Discussão dos resultados, identificação de limitações e proposição de trabalhos futuros.

O restante deste documento está organizado da seguinte forma: no Capítulo 2 são apresentados os objetivos da pesquisa. No Capítulo 3 são apresentados conceitos gerais necessários ao entendimento do problema, como reconhecimento de entidades nomeadas (NER), modelos estatísticos de sequência e modelos de linguagem de grande porte. O Capítulo 4 reúne e discute trabalhos relacionados à extração de entidades por meio de modelos baseados em regras, modelos estatísticos e LLMs, destacando abordagens correlatas ao problema de pesquisa. Já o Capítulo 5 descreve o problema prático de integração de LLMs em pipelines já existentes, baseados em CRF e regras linguísticas, destacando desafios e requisitos. O Capítulo 6 detalha os procedimentos adotados, incluindo dataset, pré-processamento, seleção do modelo GPT-4.1 Nano, engenharia de prompts e mapeamento de entidades. O Capítulo 7 apresenta e discute os resultados dos experimentos, comparando o desempenho do LLM com o modelo estatístico e com o modelo baseado em regras. Por fim, o Capítulo 8 sintetiza as principais contribuições, discute os benefícios do estudo, verifica o atendimento aos objetivos, aponta limitações e sugere direções para trabalhos futuros.

2 OBJETIVOS

2.1 Objetivo Geral

O objetivo geral deste trabalho é realizar uma avaliação exploratória da extração e classificação de entidades por meio da API GPT-4.1 Nano, comparando seu desempenho com um modelo CRF e com uma anotação de referência baseada em regras (corpus BOSQUE), e discutir criticamente os resultados à luz das limitações metodológicas.

2.2 Objetivos Específicos

- a. Descrever a evolução histórica das técnicas de extração de entidades, desde modelos baseados em regras até LLMs.
- b. Implementar uma API em Python/Django para envio de sentenças a um LLM e coleta de resultados em formato estruturado.
- c. Projetar prompts específicos para extração de entidades em formato IOB e para rotulagem morfosintática (UPOS) com identificação de intenção.
- d. Comparar, de forma descritiva, os resultados da GPT-4.1 Nano com um modelo estatístico de CRF em um subconjunto de sentenças anotadas.
- e. Comparar, de forma descritiva, os resultados da GPT-4.1 Nano com a anotação de referência baseada em regras (BOSQUE) em um subconjunto de sentenças.
- f. Realizar análise qualitativa dos tipos de erros cometidos pelo LLM, incluindo alucinações, trocas de rótulo e inconsistências de formato.
- g. Discutir de que forma o LLM pode atuar como componente complementar às abordagens tradicionais, em vez de substituto direto.

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta conceitos gerais relacionados ao processamento de linguagem natural, reconhecimento de entidades nomeadas, modelos estatísticos de sequência e modelos de linguagem de grande porte, fornecendo base para o entendimento do problema em estudo.

3.1 Reconhecimento de Entidades Nomeadas

O Reconhecimento de Entidades Nomeadas (NER – **Named Entity Recognition**) é a tarefa de identificar e categorizar entidades relevantes em um texto, tais como pessoas, organizações, locais, datas, valores monetários e outras categorias específicas (MOHIT, 2014). Em termos gerais, um sistema de NER recebe como entrada uma sequência de palavras e produz, como saída, rótulos que indicam quais tokens pertencem a quais entidades. Uma convenção bastante utilizada é o esquema de anotação IOB (Inside–Outside–Beginning), no qual:

- **B:** Indica o início de uma entidade;
- **I:** Indica continuidade da mesma entidade;
- **O:** Indica tokens fora de qualquer entidade.

Esse esquema permite rotular, por exemplo, nomes compostos e entidades multi-palavra de forma estruturada, o que é particularmente útil em tarefas de extração em linguagem natural.

3.2 Modelos Estatísticos de Sequência

Com o amadurecimento do PLN, modelos estatísticos de sequência passaram a ser amplamente empregados em tarefas como NER, etiquetagem mórfico-sintática e segmentação. Entre as técnicas clássicas, destacam-se os Modelos de Markov Ocultos (HMMs – Hidden Markov Models) e os Campos Aleatórios Condicionais (CRFs – Conditional Random Fields) (BAUM et al., 1970), (LAFFERTY et al., 2001). Esses modelos aprendem, a partir de corpora anotados, probabilidades de transição entre rótulos (por exemplo, B-per, I-per, O) e distribuições associadas a características dos tokens (palavra, capitalização, sufixos, etc.). Embora eficazes em muitos cenários, tais abordagens apresentam limitações importantes:

- Dependência de grande volume de dados anotados manualmente;
- Modelagem predominantemente local do contexto;
- Dificuldade para capturar dependências de longo alcance e nuances semânticas mais complexas (KERAGHEL; MORBIEU; NADIF, 2024).

3.3 Modelos de Linguagem de Grande Porte

Modelos de Linguagem de Grande Porte (LLMs) são redes neurais com número elevado de parâmetros, treinadas sobre grandes quantidades de texto, utilizando tarefas como modelagem de linguagem mascarada ou predição autoregressiva (YAO et al., 2024). Por meio desse treinamento massivo, os modelos aprendem a estimar distribuições de probabilidade sobre sequências de palavras, capturando informação sintática, semântica e pragmática em diferentes níveis de abstração. Esses modelos são geralmente construídos sobre a arquitetura de transformers, centrada no mecanismo de atenção. Diferentemente de redes recorrentes, a arquitetura transformer abandona a recorrência explícita e utiliza exclusivamente a atenção para capturar dependências globais entre entradas e saídas (VASWANI et al., 2017). Isso permite:

- Aprendizado eficiente de dependências de longo alcance;
- Processamento paralelo mais eficiente durante o treinamento;
- Maior capacidade de generalização para diferentes tarefas de linguagem.

3.4 Engenharia de Prompt

Com o uso de LLMs em regime de in-context learning, a engenharia de prompt (prompt engineering) emerge como prática fundamental. O objetivo é construir textos de entrada (prompts) que orientem o modelo a produzir respostas adequadas a uma tarefa específica, sem necessidade de re-treinamento (YE et al., 2023). No contexto de extração de entidades, a engenharia de prompt consiste em:

- Descrever claramente a tarefa (por exemplo, “você é um sistema de NER”).
- Definir o conjunto de rótulos possíveis (tags IOB, categorias de entidades etc.).
- Especificar o formato de saída (por exemplo, JSON com pares (token, rótulo)).
- Fornecer exemplos ilustrativos de entradas e saídas.

Esse alinhamento entre instruções, exemplos e formato de saída é crucial para obter resultados consistentes na extração automatizada de entidades com LLMs.

4 REVISÃO BIBLIOGRÁFICA

Este capítulo apresenta uma revisão de trabalhos relacionados ao problema em estudo, com foco em abordagens para extração de entidades em assistentes de IA, abrangendo modelos baseados em regras, modelos estatísticos e métodos com LLMs.

4.1 Modelos Baseados em Regras para Extração de Entidades

Modelos baseados em regras demandam a definição manual de intenções e de padrões linguísticos que descrevam a forma como o usuário formula comandos, bem como o mapeamento das entidades envolvidas em cada intenção. Um exemplo amplamente conhecido é o assistente virtual Alexa, cujas skills exigem que linguistas e desenvolvedores antecipem as possíveis variações de enunciados dos usuários, definindo, por meio do Console de Desenvolvedor da Amazon, como as entidades se alinham a cada intenção (KURATOV et al., 2020). Nessa abordagem, linguagens como AIML (Artificial Intelligence Markup Language) e ferramentas semelhantes são utilizadas para descrever regras de diálogo. Entretanto, a necessidade de cobrir manualmente um grande número de variações torna o processo trabalhoso e pouco escalável (THORAT; JADHAV, 2020). Em ambientes com ampla variação linguística, como o português brasileiro, essa limitação se torna ainda mais evidente.

4.2 Modelos Estatísticos para NER

A partir dos anos 2000, modelos estatísticos de rotulagem sequencial, como HMMs e CRFs, passaram a ser empregados de forma sistemática em NER (BAUM et al., 1970), (LAFFERTY et al., 2001). Esses modelos substituem parte do esforço de construção manual de regras por aprendizado automático a partir de corpus anotados. Estudos como (KERAGHEL; MORBIEU; NADIF, 2024) apresentam análises comparativas de diferentes implementações de NER, considerando domínios, tamanhos de corpus e categorias de entidades. De maneira geral, esses trabalhos demonstram que modelos estatísticos alcançam bons resultados quando há disponibilidade de dados anotados de qualidade, mas mantêm limitações em termos de:

- Adaptação a novos domínios;
- Tratamento de ambiguidades contextuais complexas;
- Necessidade de re-treinamento quando há mudança no esquema de entidades.

4.3 Abordagens com LLMs para Extração de Entidades

Com a disseminação de LLMs, novos trabalhos passaram a explorar sua capacidade de realizar NER e tarefas correlatas por meio de prompts, sem necessidade de treinamento supervisionado específico. Esses estudos mostram que LLMs podem:

- Generalizar para novas classes de entidades a partir de instruções textuais.
- Adaptar-se rapidamente a variações de domínio e estilo linguístico.
- Incorporar conhecimento contextual mais amplo na decisão de rotulagem.

Ao mesmo tempo, a literatura aponta limitações, como:

- Suscetibilidade a alucinações.
- Falta de garantias de consistência em saídas estruturadas (por exemplo, JSON).
- Necessidade de projetar prompts robustos e controlados.

Este trabalho insere-se nesse contexto, ao utilizar um LLM compacto, a GPT-4.1 Nano, para realizar extração de entidades e classificação de sentenças, comparando seus resultados com modelos tradicionais (CRF e regras) em um cenário controlado.

5 DESCRIÇÃO DO PROBLEMA EM ESTUDO

O problema prático abordado neste trabalho surge em cenários em que já existe uma infraestrutura de extração de entidades baseada em:

- Modelos estatísticos de CRF treinados sobre um corpus anotado por linguistas.
- Modelo baseado em regras construído a partir do corpus BOSQUE (UD Portuguese Bosque), que segue o framework de Universal Dependencies (RADEMAKER et al., 2017).

Nessa arquitetura, novas sentenças precisam ser mapeadas para rótulos de entidades e categorias gramaticais, de modo a alimentar assistentes de IA e pipelines de entendimento de linguagem. Entretanto, a expansão do domínio (novos tipos de comandos, variação linguística, inclusão de dados não mapeados previamente) torna a manutenção desses modelos progressivamente mais onerosa. Em particular, o trabalho foca em três desafios:

- a. Integração de LLM ao pipeline existente: avaliar se um LLM consegue reproduzir, com boa aproximação, o comportamento dos modelos tradicionais (CRF e regras), sem necessidade de re-treinar modelos específicos.
- b. Generalização para sentenças novas: verificar o desempenho do LLM em sentenças inéditas, não presentes originalmente nos corpora anotados por linguistas.
- c. Identificação de lacunas e oportunidades: analisar casos em que o LLM identifica entidades que os modelos tradicionais não detectam, bem como casos em que comete erros ou alucinações.

Figuras, fluxogramas e tabelas (apresentadas nos capítulos seguintes) são utilizadas para ilustrar a comparação entre os diferentes modelos e tornar mais claras as especificidades do problema em estudo.

6 METODOLOGIA

A metodologia adotada neste trabalho consiste em utilizar corpora curados por linguistas e projetar prompts específicos para um modelo de linguagem de grande porte (LLM), com o objetivo de automatizar a extração de entidades e avaliar a acurácia dos resultados em comparação com abordagens tradicionais (modelo estatístico de CRF e anotação baseada em regras). Uma API foi implementada utilizando o framework Django, responsável por receber sentenças, encaminhá-las ao LLM GPT-4.1 Nano e retornar o resultado da análise em formato estruturado (JSON). Os prompts foram elaborados de forma a refletir a estrutura dos corpora anteriormente usados com o CRF e com a anotação de referência BOSQUE.

6.1 Dataset e Pré-Processamento

Foram utilizados dois conjuntos principais de sentenças anotadas, originalmente curados por linguistas:

(i) Conjunto CRF (150 sentenças): subconjunto de um corpus anotado para NER em esquema IOB, empregado no treinamento prévio de um modelo estatístico de Conditional Random Fields (CRF). Essas 150 sentenças foram selecionadas para permitir comparação direta entre as saídas do CRF e da GPT-4.1 Nano.

(ii) Conjunto BOSQUE (1167 sentenças): subconjunto do treebank BOSQUE Português, integrante do projeto Floresta Sintática e convertido ao formato Universal Dependencies (UD) (RADEMAKER et al., 2017). Nesse corpus, as sentenças são anotadas com rótulos de classe de palavras (UPOS) e outras informações sintáticas.

No caso do CRF, o modelo estatístico foi treinado anteriormente utilizando um conjunto de treinamento maior, e, para este trabalho, apenas o conjunto de teste com 150 sentenças foi utilizado para comparação. No caso do BOSQUE, a anotação é considerada ground truth, produzida originalmente com apoio de gramáticas de restrição, regras linguísticas e revisão humana. É importante destacar que o tamanho do conjunto de 150 sentenças para NER é reduzido, o que limita a significância estatística dos resultados. Por esse motivo, a análise aqui apresentada é de caráter exploratório e descritivo, não havendo pretensão de generalizar quantitativamente o desempenho dos modelos para outros domínios ou corpora.

As sentenças foram normalizadas, tokenizadas e organizadas em arquivos distintos, de forma a serem processadas tanto pelos modelos tradicionais (CRF e anotação BOSQUE)

quanto pelo LLM. A interface de comunicação com o LLM, implementada em Django, recebe cada sentença, aplica o prompt adequado e armazena a resposta em JSON para posterior comparação.

6.2 Modelos de Referência

Dois referenciais são utilizados como base de comparação ao LLM:

(i) Modelo estatístico de CRF: modelo de Conditional Random Fields treinado previamente para NER em esquema IOB, com base em corpus anotado por linguistas (LAFFERTY et al., 2001). Neste trabalho, o CRF é utilizado apenas em modo de inferência, aplicando-o às 150 sentenças do conjunto de teste e comparando suas saídas com as saídas da GPT-4.1 Nano.

(ii) Anotação baseada em regras (BOSQUE): no contexto deste estudo, o chamado “modelo baseado em regras” não corresponde a um novo sistema implementado pelos autores, mas sim à anotação de referência do treebank BOSQUE Português (RADEMAKER et al., 2017). Essa anotação foi originalmente produzida por meio de gramáticas de restrição e regras linguísticas, com revisão humana subsequente, sendo tratada aqui como linha de base determinística para POS tagging.

Dessa forma, quando se fala em “modelo baseado em regras”, o sentido adotado é o de rotulagem de referência derivada de um processo baseado em regras, utilizada como gold standard para fins de comparação.

6.3 Modelo de Linguagem GPT-4.1 Nano

O modelo de linguagem utilizado neste estudo é a variante GPT-4.1 Nano, acessível via API proprietária no período de realização dos experimentos. Trata-se de um modelo de linguagem de grande porte otimizado para baixa latência e uso em aplicações embarcadas, pertencente à família GPT-4.1. Por se tratar de um modelo fechado, não há disponibilidade pública de detalhes completos de arquitetura, hiperparâmetros ou dados de treinamento. Essa característica impõe uma limitação importante de reprodutibilidade: outros pesquisadores somente poderão reproduzir integralmente os resultados aqui apresentados se tiverem acesso à mesma API, na mesma versão e configuração.

De forma geral, a GPT-4.1 Nano apresenta as seguintes características relevantes para este estudo:

- Suporte a janelas de contexto extensas (até 1 milhão de tokens), permitindo o processamento de entradas e saídas mais longas;

- Capacidade de seguir instruções complexas via prompt, produzindo saídas estruturadas (por exemplo, JSON);
- Adequação a aplicações em tempo real, como assistentes de IA e serviços de anotação sob demanda.

Em vez de um estudo de comparação exaustiva entre arquiteturas, este trabalho utiliza a GPT-4.1 Nano como um estudo de caso de LLM fechado, avaliando empiricamente seu comportamento em tarefas de NER e etiquetagem morfosintática sob condições controladas.

6.4 Engenharia de Prompts

Dois prompts principais foram projetados, cada um alinhado a um dos modelos de referência (estatístico e baseado em regras), com o objetivo de aproximar o formato de saída do LLM ao formato dos corpora de comparação.

6.4.1 Primeiro Prompt: Extração em Formato IOB (comparação com CRF)

O primeiro prompt espelha a estrutura do corpus anotado usado com o modelo de CRF, utilizando o esquema IOB para rotulagem de entidades. O LLM é instruído a agir como um sistema de NER e classificação de intenção, com saída obrigatória em formato JSON. A seguir, apresenta-se um trecho representativo do prompt (Figura 1).

Figura 1 – Prompt para a LLM comparar com o modelo estatístico CRF

```
You are a named entity recognition (NER) and classification system.
Your job is to identify the user's intent from the sentence and tag
each word with an IOB tag for entity recognition.

Possible tags are:
B-geo, I-geo, B-org, I-org, B-per, I-per, ...
O: Outside any entity

Important rules:
- The output must be valid JSON...
- Each word in the sentence should have its own IOB tag...
- The response must include the user's intent...
...
Phrase: "{{phrase}}"
```

Fonte: Elaborado pelo autor

Esse prompt obriga o modelo a fornecer para cada sentença um objeto JSON contendo: (i) a intenção inferida ("intent") e (ii) uma lista de pares ["palavra", "tag"] em IOB.

Essa estrutura permite comparação direta com a saída do CRF, que também retorna rótulos IOB por token.

6.4.2 Segundo Prompt: Rotulagem UPOS e Intenção (comparação com BOSQUE)

O segundo prompt tem como base a estrutura do corpus BOSQUE, alinhado aos padrões Universal Dependencies. Ele orienta o LLM a atuar como um etiquetador morfossintático (POS tagger) e classificador de intenção, também com saída em JSON. Um trecho simplificado é apresentado a seguir (Figura 2).

Figura 2 – Prompt para a LLM comparar com o modelo baseado em regras

```
You are a part-of-speech tagging system (POS tagger) and intent
classifier.
Your task is to analyze the sentence, assign a UPOS tag to each word
,
and identify the user's intent.

Use the following valid UPOS tags only:
ADJ, ADP, ADV, AUX, CCONJ, DET, INTJ, NOUN, NUM,
PART, PRON, PROPN, PUNCT, SCONJ, SYM, VERB, X

Output format example:
{
  "intent": "localizar_usuario",
  "result": [
    ["Ele", "PRON"],
    ["est ", "AUX"],
    ["em", "ADP"],
    ["S o", "PROPN"],
    ["Paulo", "PROPN"],
    [".", "PUNCT"]
  ]
}

Phrase: "{{phrase}}"
```

Fonte: Elaborado pelo autor

Novamente, o LLM retorna um JSON com a intenção e a lista de pares ["palavra", "UPOS"], permitindo comparação estruturada com a anotação do corpus BOSQUE.

6.5 Mapeamento de Entidades, Métricas e Procedimentos de Avaliação

Os resultados produzidos pela GPT-4.1 Nano foram comparados com as anotações dos modelos de referência, tanto para o corpus do CRF quanto para o BOSQUE. A partir dessa comparação, foram geradas:

- Tabelas de comparação de resultados: exibem, para cada token, a classificação produzida pelo modelo de referência e pelo LLM, juntamente com a intenção inferida;
- Tabelas de métricas: apresentam, para cada modelo, as métricas de precisão e cobertura na tarefa de NER e de POS tagging;
- Tabelas de discrepâncias: listam entidades ou rótulos identificados exclusivamente pelo LLM, tanto em relação ao modelo estatístico quanto em relação ao referencial BOSQUE.

As métricas principais utilizadas foram:

- Precisão (Precision): proporção de entidades (ou rótulos) identificadas pelo modelo que são de fato corretas, segundo o corpus de referência;
- Cobertura (Recall): proporção de entidades (ou rótulos) presentes no corpus de referência que são corretamente recuperadas pelo modelo.

A análise dos resultados combina essas métricas quantitativas com uma inspeção qualitativa dos erros, buscando identificar padrões de falhas (como alucinações, erros de tipo e de fronteira de entidades) e casos em que o LLM sugere rótulos plausíveis ausentes nos modelos de referência.

6.6 Natureza Exploratória do Estudo

Dadas as limitações de tamanho do conjunto de dados (especialmente as 150 sentenças para NER), a ausência de controle sobre a arquitetura interna do LLM e o foco em apenas um idioma e dois corpora específicos, este trabalho deve ser interpretado como um estudo exploratório. As comparações numéricas servem para ilustrar tendências e levantar hipóteses, e não para estabelecer conclusões definitivas sobre a superioridade de uma abordagem sobre outra em contextos gerais.

7 RESULTADOS

Esta seção apresenta os resultados dos experimentos conduzidos com a GPT-4.1 Nano, em comparação com o modelo estatístico de CRF (para NER) e com a anotação baseada em regras do BOSQUE (para POS tagging). Em todos os casos, as métricas são interpretadas à luz das limitações discutidas na Metodologia.

7.1 Resultados para NER: CRF x GPT-4.1 Nano

No conjunto de 150 sentenças anotadas em esquema IOB, a comparação entre o modelo de CRF e a GPT-4.1 Nano resultou nas métricas apresentadas no Quadro 1.

Quadro 1 – Relatório de métricas de NER: CRF x GPT-4.1 Nano

Modelo	Precisão	Cobertura
CRF	0.82	0.71
GPT-4.1 Nano	0.52	0.64

Fonte: Elaborada pelo autor

Observa-se que, neste conjunto de teste, o modelo de CRF supera a GPT-4.1 Nano em ambas as métricas agregadas, com diferença particularmente acentuada em precisão (0,82 vs 0,52). A cobertura do LLM é levemente inferior à do CRF (0,64 vs 0,71), de modo que não se pode afirmar, com base nesses dados, que haja vantagem quantitativa do LLM em NER. Do ponto de vista descritivo, algumas características emergem:

- O CRF tende a ser mais conservador, deixando de marcar certas entidades marginais, mas, quando marca, acerta com maior frequência;
- A GPT-4.1 Nano tende a rotular mais tokens como entidades, apresentando maior número de falsos positivos, o que explica a queda de precisão.

Esses resultados contrariam a expectativa intuitiva de que um LLM necessariamente teria desempenho igual ou superior ao modelo estatístico em um cenário supervisionado bem alinhado ao corpus. Eles indicam que, ao menos neste conjunto de 150 sentenças e com o prompt adotado, o CRF mantém vantagem clara em NER.

7.2 Resultados para POS Tagging: BOSQUE x GPT-4.1 Nano

No conjunto de 1 167 sentenças do BOSQUE, a comparação entre a anotação de referência (derivada de regras e revisão humana) e a saída da GPT-4.1 Nano resultou nas métricas do Quadro 2.

Quadro 2 – Relatório de métricas de POS tagging: anotação BOSQUE x GPT-4.1 Nano

Modelo	Precisão	Cobertura
Anotação BOSQUE (ground truth)	0.90	0.93
GPT-4.1 Nano	0.81	0.79

Fonte: Elaborada pelo autor.

Como esperado, a anotação de referência, construída ao longo de anos com base em regras linguísticas e revisão manual, supera a saída do LLM em ambas as métricas. Ainda assim, a GPT-4.1 Nano alcança valores relativamente altos de precisão (0,81) e cobertura (0,79), o que sugere capacidade de aproximação razoável ao padrão de anotação UD em um contexto sem treinamento específico. Entretanto, assim como em NER, os números não sustentam a interpretação de que o LLM tenha desempenho “próximo” ou equivalente ao referencial: a diferença de cerca de 9 pontos percentuais em precisão e 14 pontos em cobertura é substancial.

7.3 Entidades e Rótulos Identificados Apenas pelo LLM

Apesar do desempenho inferior em métricas agregadas, a GPT-4.1 Nano apresenta um comportamento interessante: em alguns casos, identifica entidades e padrões gramaticais que não foram marcados pelos modelos de referência. A Tabela 3 ilustra um exemplo no contexto de NER.

Quadro 3 – Modelo estatístico: entidades extraídas apenas pela GPT-4.1 Nano

Token	GPT-4.1 Nano	CRF	Sentença
Helicopter	B-art	O	Helicopter gunships Saturday pounded militant hideouts in the Orakzai tribal region, where many Taliban militants are believed to have fled to avoid an earlier military offensive in nearby South Waziristan.
gunships	I-art	O	Helicopter gunships Saturday pounded militant hideouts in the Orakzai tribal region, where many Taliban militants are believed to have fled to avoid an earlier military offensive in nearby South Waziristan.

Fonte: Elaborado pelo autor

Nesse exemplo, o LLM interpreta “Helicopter gunships” como um artefato, enquanto o CRF não marca nenhuma entidade. Em cenários de aplicação prática, esse tipo de sensibilidade semântica pode ser útil para enriquecer anotações ou sugerir novas categorias, desde que haja uma camada de validação. De forma semelhante, na comparação com o BOSQUE, a GPT-4.1 Nano atribui rótulos UPOS a tokens que aparecem não anotados ou com anotação menos granular, evidenciando certa capacidade de generalização. Esses casos, contudo, são pontuais e não compensam, em termos quantitativos, a diferença agregada de desempenho.

7.4 Análise de Erros da GPT-4.1 Nano

Uma análise qualitativa dos erros aponta para alguns padrões recorrentes:

7.4.1 Erros de Tipo de Entidade

Um exemplo particularmente ilustrativo é o caso em que a GPT-4.1 Nano classifica “Russian” em “Russian officials say...” como fenômeno natural (B-nat), enquanto o CRF a classifica corretamente como entidade geopolítica (B-gpe). Trata-se de um erro semântico grave, em que o modelo confunde uma nacionalidade/país com uma categoria de fenômeno natural. Esse tipo de erro sugere que, embora o LLM tenha acesso a vasto conhecimento textual, a forma como o prompt define as categorias (por exemplo, B-nat para fenômenos naturais) pode induzir confusões quando há sobreposição semântica ou ambiguidade.

7.4.2 Erros de Fronteira de Entidade

Em outros casos, o LLM identifica corretamente a presença de uma entidade, mas se equivoca na fronteira (por exemplo, incluindo determinantes adjacentes na entidade ou dividindo uma expressão multi-palavra em duas entidades separadas). Esses erros são comuns em NER e aparecem tanto em modelos estatísticos quanto em LLMs, mas podem ser especialmente problemáticos quando se espera uma saída estritamente padronizada.

7.4.3 Alucinações e Marcação Excessiva

Também foram observadas situações em que a GPT-4.1 Nano atribui rótulos de entidade a tokens que não possuem evidência clara de serem entidades, caracterizando alucinações. Em parte, isso explica a queda de precisão: o modelo “arrisca” mais, marcando entidades onde o referencial é mais conservador.

7.4.4 Inconsistências de Formato

Apesar de o prompt exigir saída em JSON bem formado, em alguns poucos casos o LLM retornou respostas com pequeno desvio de formato (por exemplo, vírgulas faltantes). Esses casos foram tratados manualmente na análise, mas evidenciam a necessidade de mecanismos de validação automática quando LLMs são usados em pipelines de produção. Essa análise de erros reforça a conclusão de que LLMs, por si só, não substituem de maneira trivial modelos consolidados em tarefas de anotação linguística, mas podem atuar como fontes adicionais de sinal semântico, desde que haja camadas de controle e validação.

8 CONCLUSÕES

Este trabalho analisou, em caráter exploratório, a utilização de um modelo de linguagem de grande porte (GPT-4.1 Nano) em tarefas de extração de entidades (NER) e etiquetagem morfosintática (POS tagging), em comparação com um modelo estatístico de CRF e com uma anotação de referência baseada em regras (BOSQUE). A partir da implementação de uma API em Django, da definição de prompts específicos e da comparação com linhas de base consolidadas, foi possível caracterizar, com dados concretos, vantagens e limitações práticas da abordagem baseada em LLM.

8.1 Considerações Finais

Do ponto de vista quantitativo, os resultados são claros:

- (i) No conjunto de 150 sentenças para NER, o modelo de CRF superou a GPT-4.1 Nano em precisão e cobertura, com diferença especialmente evidente em precisão.
- (ii) No conjunto de 1167 sentenças do BOSQUE, a anotação de referência baseada em regras apresentou desempenho superior ao LLM em ambas as métricas.

Assim, não é possível afirmar, com base nos experimentos realizados, que a GPT-4.1 Nano tenha apresentado desempenho “próximo” ou superior aos métodos tradicionais avaliados. Pelo contrário, nas condições deste estudo, as abordagens clássicas mantiveram vantagem. Por outro lado, a análise qualitativa mostrou que o LLM é capaz de:

- (i) Identificar entidades e padrões não marcados pelos modelos de referência, sugerindo potencial para enriquecimento de anotações.
- (ii) Aproximar-se de esquemas de anotação complexos (IOB, UPOS) guiado apenas por prompts, sem treinamento supervisionado específico.
- (iii) Operar como componente flexível, adaptável a novas categorias de entidades ou domínios, com custo de configuração menor do que o desenvolvimento de um novo modelo estatístico ou conjunto de regras.

Nesse sentido, a principal contribuição prática do trabalho não é demonstrar superioridade do LLM, mas sim delimitar com maior precisão o seu papel: como ferramenta complementar, capaz de gerar hipóteses, sugerir rótulos e acelerar etapas de prototipagem, mas que ainda não substitui, de forma simples, modelos consolidados em pipelines de produção para NER e POS tagging.

8.2 Verificação dos Objetivos Atingidos

Em relação aos objetivos estabelecidos:

- (i) Foi descrita a evolução das técnicas de extração de entidades, situando modelos baseados em regras, modelos estatísticos e LLMs na literatura.
- (ii) Foi implementada uma API em Python/Django para interação com a GPT-4.1 Nano e coleta de saídas em formato estruturado.
- (iii) Foram projetados prompts específicos para NER (IOB) e POS tagging (UPOS) com identificação de intenção.
- (iv) Foram realizadas comparações descritivas entre o LLM, um modelo de CRF e a anotação de referência BOSQUE, com cálculo de métricas de precisão e cobertura.
- (v) Foi conduzida uma análise qualitativa dos erros do LLM, incluindo casos de alucinações e confusão de tipos de entidade.
- (vi) Foram discutidos cenários em que o LLM pode atuar como complemento aos métodos tradicionais.

Os objetivos foram, portanto, atingidos, ainda que os resultados obtidos tenham contrariado algumas expectativas iniciais de desempenho do LLM.

8.3 Limitações do Estudo

As principais limitações observadas são:

- (i) Tamanho reduzido do conjunto de NER (150 sentenças), insuficiente para conclusões estatisticamente robustas.
- (ii) Uso de um LLM fechado, sem acesso público aos detalhes de arquitetura e dados de treinamento, o que compromete a reprodutibilidade estrita.
- (iii) Foco em apenas dois corpora específicos, ambos com características particulares (um corpus de NER e o BOSQUE-UD), o que limita a generalização para outros domínios e gêneros textuais.
- (iv) Ausência de comparação com outros LLMs acessíveis publicamente (por exemplo, modelos de código aberto), que poderia fornecer quadro mais amplo.

8.4 Sugestões para Trabalhos Futuros

Como desdobramentos naturais deste estudo, sugerem-se:

- (i) Repetir os experimentos com conjuntos de dados de avaliação maiores e padronizados, permitindo análise estatística mais robusta.
- (ii) Incluir, na comparação, LLMs de código aberto (por exemplo, modelos baseados em LLAMA ou outros), com configurações documentadas e reprodutíveis.
- (iii) Explorar técnicas de prompt optimization e prompt tuning, avaliando em que medida

ajustes sistemáticos de prompts podem reduzir erros e alucinações.

(iv) Investigar arquiteturas híbridas que combinam LLMs com modelos estatísticos ou regras, por exemplo, usando o LLM para sugerir rótulos e um módulo clássico para validação.

(v) Estender a análise para outros idiomas e domínios (jurídico, biomédico, etc.), avaliando o impacto de variações terminológicas na qualidade da extração.

Em síntese, os resultados reforçam que modelos de linguagem de grande porte representam uma ferramenta poderosa e versátil, mas que sua adoção em tarefas de anotação linguística requer cuidado metodológico, mecanismos de controle de qualidade e uma visão realista de suas capacidades e limitações.

REFERÊNCIAS

- BAUM, Leonard E. et al. A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains. *The Annals of Mathematical Statistics*, v. 41, n. 1, p. 164–171, 1970.
- FLORIAN, Radu et al. A statistical model for multilingual entity detection and tracking. In: *Proceedings of the Human Language Technology Conference of the North American Chapter of the Association for Computational Linguistics (HLT-NAACL 2004)*. [S.l.: s.n.], 2004. p. 1–8.
- IOKU, Tomohiro; SONG, Jaehyun; WATAMURA, Eiichiro. Trade-offs in AI assistant choice: Do consumers prioritize transparency and sustainability over AI assistant performance? *Big Data & Society*, v. 11, n. 4, p. 20539517241290217, 2024. Disponível em: <https://doi.org/10.1177/20539517241290217>. Acesso em: 10 nov. 2025.
- JIVANI, Farzeem D.; MALVANKAR, Manohar; SHANKARMANI, Radha. A voice controlled smart home solution with a centralized management framework implemented using AI and NLP. In: *2018 International Conference on Current Trends towards Converging Technologies (ICCTCT)*. [S.l.: s.n.], 2018. p. 1–5. Disponível em: <https://doi.org/10.1109/ICCTCT.2018.8550972>. Acesso em: 10 nov. 2025.
- KERAGHEL, Imed; MORBIEU, Stanislas; NADIF, Mohamed. Recent advances in named entity recognition: A comprehensive survey and comparative study. Working paper or preprint, 2024. Disponível em: <https://hal.science/hal-04488194>. Acesso em: 10 nov. 2025.
- KURATOV, Yuri et al. Dream technical report for the Alexa Prize 2019. *Alexa Prize Proceedings*, 2020.
- LAFFERTY, John; MCCALLUM, Andrew; PEREIRA, Fernando. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In: *Proceedings of the Eighteenth International Conference on Machine Learning (ICML)*. Williamstown, MA: [s.n.], 2001. p. 282–289.
- MOHIT, Behrang. Named entity recognition. In: ZITOUNI, Imed (ed.). *Natural Language Processing of Semitic Languages*. Berlin; Heidelberg: Springer, 2014. p. 221–245. Disponível em: https://doi.org/10.1007/978-3-642-45358-8_7. Acesso em: 10 nov. 2025.
- RADEMAKER, Alexandre et al. Universal dependencies for Portuguese. In: *Proceedings of the Fourth International Conference on Dependency Linguistics (Depling)*. Pisa, Italy: [s.n.], 2017. p. 197–206. Disponível em: <http://aclweb.org/anthology/W17-6523>. Acesso em: 15 nov. 2025.
- THORAT, Sandeep A.; JADHAV, Vishakha. A review on implementation issues of rule-based chatbot systems. In: *Proceedings of the International Conference on Innovative Computing & Communications (ICICC 2020)*. [S.l.: s.n.], 2020. Disponível em: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3567047. Acesso em: 10 nov. 2025.
- VASWANI, Ashish et al. Attention is all you need. In: GUYON, Isabelle et al. (ed.). *Advances in Neural Information Processing Systems*. Red Hook, NY: Curran Associates, Inc., 2017. v. 30. Disponível em:

https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf. Acesso em: 18 nov. 2025.

YANG, Jingfeng et al. Harnessing the power of LLMs in practice: A survey on ChatGPT and beyond. *ACM Transactions on Knowledge Discovery from Data*, v. 18, n. 6, abr. 2024. Disponível em: <https://doi.org/10.1145/3649506>. Acesso em: 21 nov. 2025.

YAO, Yifan et al. A survey on large language model (LLM) security and privacy: The good, the bad, and the ugly. *High-Confidence Computing*, v. 4, n. 2, p. 100211, 2024. Disponível em: <https://www.sciencedirect.com/science/article/pii/S266729522400014X>. Acesso em: 30 nov. 2025.

YE, Qinyuan et al. Prompt engineering a prompt engineer. *arXiv preprint*, arXiv:2311.05661, 2023. Disponível em: <https://arxiv.org/abs/2311.05661>. Acesso em: 5 dez. 2025.